Ex 5: Predicting Custumer Churn

- Cho dữ liệu Churn_Modelling.csv chứa thông tin của 10000 khách hàng của công ty.
- Là phụ trách bộ phận chăm sóc khách hàng bạn nhận thấy việc phải xây dựng một mô hình Machine Learning để dự đoán việc khách hàng sẽ ra đi hay ở lại. Công việc này vô cùng quan trọng vì giữ chân được khách hàng càng lâu doanh nghiệp của bạn sẽ càng tiết kiệm được chi phí và tăng doanh thu.

Gợi ý

In [1]:
```
# from google.colab import drive
# drive.mount("/content/gdrive", force_remount=True)
```

In [2]:
```
# %cd '/content/gdrive/My Drive/LDS6_MachineLearning/Practice_2023/Chapter4_Decision_Tree/'
```

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score
from sklearn.metrics import confusion_matrix, roc_curve,auc
from sklearn.metrics import classification_report
import seaborn as sns
from sklearn.model_selection import train_test_split
```

Đọc dữ liệu, tiền xử lý dữ liệu

In [4]:
```
data = pd.read_csv("Churn_Modelling.csv")
```

In [5]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 14 columns):
 #   Column           Non-Null Count  Dtype  
---  ------           --------------  -----  
 0   RowNumber        10000 non-null  int64  
 1   CustomerId       10000 non-null  int64  
 2   Surname          10000 non-null  object 
 3   CreditScore      10000 non-null  int64  
 4   Geography        10000 non-null  object 
 5   Gender           10000 non-null  object 
 6   Age              10000 non-null  int64  
 7   Tenure           10000 non-null  int64  
 8   Balance          10000 non-null  float64
 9   NumOfProducts    10000 non-null  int64  
 10  HasCrCard        10000 non-null  int64  
 11  IsActiveMember   10000 non-null  int64  
 12  EstimatedSalary  10000 non-null  float64
 13  Exited           10000 non-null  int64  
dtypes: float64(2), int64(9), object(3)
memory usage: 1.1+ MB
```

In [6]:
```
data.head()
```

Out[6]:

	RowNumber	CustomerId	Surname	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	Esti
0	1	15634602	Hargrave	619	France	Female	42	2	0.00	1	1	1	
1	2	15647311	Hill	608	Spain	Female	41	1	83807.86	1	0	1	
2	3	15619304	Onio	502	France	Female	42	8	159660.80	3	1	0	
3	4	15701354	Boni	699	France	Female	39	1	0.00	2	0	0	
4	5	15737888	Mitchell	850	Spain	Female	43	2	125510.82	1	1	1	

In [7]:
```
# Dựa trên thông tin trên ta thấy các cột không dùng trong model là:
# RowNumber, CustomerId, Surname
# inputs: các cột còn lại trừ cột Exited
# output: cột Exited
```

In [8]:
```
X = data.iloc[:, 3:13]
y = data.iloc[:, 13]
```

In [9]:
```
X.head()
```

Out[9]:

	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary
0	619	France	Female	42	2	0.00	1	1	1	101348.88
1	608	Spain	Female	41	1	83807.86	1	0	1	112542.58
2	502	France	Female	42	8	159660.80	3	1	0	113931.57
3	699	France	Female	39	1	0.00	2	0	0	93826.63
4	850	Spain	Female	43	2	125510.82	1	1	1	79084.10

In [10]:
```
type(y)
```

Out[10]:
```
pandas.core.series.Series
```

In [11]:
```
y.value_counts() # 0: ở lại, 1: ra đi; tỷ lệ ~ 4:1
```

Out[11]:
```
0    7963
1    2037
Name: Exited, dtype: int64
```

In [12]:
```
# Các thuộc tính phân loại
objects = [f for f in X.columns if X.dtypes[f] == 'object']
objects
```

Out[12]:
```
['Geography', 'Gender']
```

In [13]:
```
# Xem xét thuộc tính phân loại: Geography
X.groupby(by='Geography')['CreditScore'].count()
```

Out[13]:
```
Geography
France     5014
Germany    2509
Spain      2477
Name: CreditScore, dtype: int64
```

In [14]:
```
# Dựa trên kết quả ta thấy có 3 quốc gia
# => cần chuyển sang dữ liệu kiểu số
```

In [15]:
```
# Xem xét thuộc tính phân loại: Gender
X.groupby(by='Gender')['CreditScore'].count()
```

Out[15]:
```
Gender
Female    4543
Male      5457
Name: CreditScore, dtype: int64
```

In [16]:
```
# Dựa trên kết quả ta thấy có 2 giới tính
# => cần chuyển sang dữ liệu kiểu số
```

In [17]:
```
X_new = pd.get_dummies(X)
```

In [18]:
```
X_new.head()
```

Out[18]:

	CreditScore	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Geography_France	Geography_Germany	Geo
0	619	42	2	0.00	1	1	1	101348.88	1	0	
1	608	41	1	83807.86	1	0	1	112542.58	0	0	
2	502	42	8	159660.80	3	1	0	113931.57	1	0	
3	699	39	1	0.00	2	0	0	93826.63	1	0	
4	850	43	2	125510.82	1	1	1	79084.10	0	0	

In [19]:
```
# from sklearn.preprocessing import StandardScaler
# sc = StandardScaler()
```

In [20]:
```
# X_new_1 = sc.fit_transform(X_new)
```

Áp dụng model, nhận xét kết quả

In [21]:
```
X_train, X_test, y_train, y_test = train_test_split(X_new, y,
                                                    test_size = 0.2,
                                                    random_state = 0)
```

In [22]:
```
model = DecisionTreeClassifier()
```

In [23]:
```
model.fit(X_train, y_train)
```

Out[23]:
```
DecisionTreeClassifier()
```

In [24]:
```
print('Train score: ', model.score(X_train,y_train))
```

```
Train score:  1.0
```

In [25]:
```
print('Test score: ', model.score(X_test,y_test))
```

```
Test score:  0.8005
```

In [26]:
```
# Kết quả trên cho thấy model hơi bị overfiting
```

In [27]:
```
yhat_test = model.predict(X_test)
yhat_test
```

Out[27]:
```
array([0, 0, 0, ..., 0, 0, 1], dtype=int64)
```

In [28]:
```
print("Test Accuracy is ", accuracy_score(y_test,yhat_test)*100,"%")
```

```
Test Accuracy is  80.05 %
```

In [29]:
```
cm = confusion_matrix(y_test, yhat_test)
```

In [30]:
```
cm
```

Out[30]:
```
array([[1363,  232],
       [ 167,  238]], dtype=int64)
```

In [31]:
```
print(classification_report(y_test, yhat_test))
```

```
              precision    recall  f1-score   support

           0       0.89      0.85      0.87      1595
           1       0.51      0.59      0.54       405

    accuracy                           0.80      2000
   macro avg       0.70      0.72      0.71      2000
weighted avg       0.81      0.80      0.81      2000
```

- Kết quả chưa được tốt lắm, có giải pháp nào để tốt hơn không?

In [32]:
```
# Print ROC_AUC score using probabilities
probs = model.predict_proba(X_test)
```

In [33]:
```
scores = probs[:,1]
fpr, tpr, thresholds = roc_curve(y_test, scores)
```

In [34]:
```
plt.plot([0, 1], [0, 1], linestyle='--')
plt.plot(fpr, tpr, marker='.')
plt.title("ROC Curve")
plt.xlabel("False Positive Rate")
plt.ylabel("True Positive Rate")
plt.show()
```

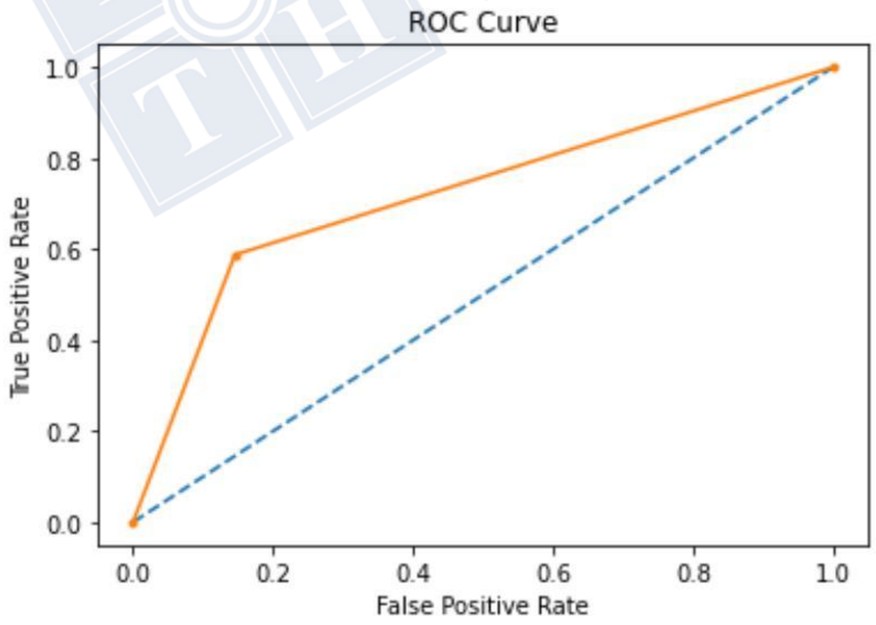

In [35]:
```
auc(fpr, tpr)
```

Out[35]:
```
0.7210998877665544
```

Predicting new samples

In [36]:
```
# Cần phải chuẩn hóa dữ liệu để mẫu mới có cùng cấu trúc với dữ liệu đang có
```

In [37]:
```
columns = X_new.columns
columns
```

Out[37]:
```
Index(['CreditScore', 'Age', 'Tenure', 'Balance', 'NumOfProducts', 'HasCrCard',
       'IsActiveMember', 'EstimatedSalary', 'Geography_France',
       'Geography_Germany', 'Geography_Spain', 'Gender_Female', 'Gender_Male'],
      dtype='object')
```

In [38]:
```
new_samples = X.iloc[[0, 1, 2]]
```

In [39]:
```
new_samples =  pd.get_dummies(new_samples)
```

In [40]:
```
new_samples.columns
```

Out[40]:
```
Index(['CreditScore', 'Age', 'Tenure', 'Balance', 'NumOfProducts', 'HasCrCard',
       'IsActiveMember', 'EstimatedSalary', 'Geography_France',
       'Geography_Spain', 'Gender_Female'],
      dtype='object')
```

In [41]:
```
missing_cols = set(X_new.columns) - set(new_samples.columns)
missing_cols
```

Out[41]:
```
{'Gender_Male', 'Geography_Germany'}
```

In [42]:
```
for c in missing_cols:
    new_samples[c] = 0
# Ensure the order of column in the test set
# is in the same order than in train set
new_samples = new_samples[X_new.columns]
```

In [43]:
```
new_samples.columns
```

Out[43]:
```
Index(['CreditScore', 'Age', 'Tenure', 'Balance', 'NumOfProducts', 'HasCrCard',
       'IsActiveMember', 'EstimatedSalary', 'Geography_France',
       'Geography_Germany', 'Geography_Spain', 'Gender_Female', 'Gender_Male'],
      dtype='object')
```

In [44]:
```
#new_samples = sc.transform(new_samples)
```

In [45]:
```
new_predictions = model.predict(new_samples)
new_predictions
```

Out[45]:
```
array([1, 0, 1], dtype=int64)
```

Kết luận:

- Kết quả có phù hợp chưa? Có giải pháp nào giúp cho kết quả cải thiện hơn không? Đề xuất

In [ ]:
```
```