

Chapter 5: Data Pre-processing

Ex2: AA data

Cho dữ liệu về thông tin các chuyển bay trong thư mục "AA_data"

Yêu cầu:

- 1. Đọc dữ liệu => df
- 2. Cho biết dữ liệu có bao nhiêu dòng, in scheme. Hiển thị 5 dòng dữ liệu đầu tiên.
- 3. Kiểm tra dữ liệu NaN, null
- 4. Kiểm tra dữ liệu trùng. Xóa dữ liệu trùng.
- 5. Trong df, thêm cột 'airport' lấy dữ liệu từ cột 'Destination Airport', định dạng chữ thường cho nôi dung
- 6. Trong df, thêm cột 'date' lấy dữ liệu từ cột 'Date (MM/DD/YYYY)', sau đó xóa bỏ cột 'Date (MM/DD/YYYY)'
- 7. Trong df, đổi tên cột "Flight Number" thành "flight_num", cột "Actual elapsed time (Minutes)" thành "actual time"
- 8. Lưu df dưới dạng Parquet format với tên là "AA DFW ALL.parquet"
- 9. Đọc parquet "AA_DFW_ALL.parquet" => df_new
- 10. Tạo một bảng tạm 'flights'. Cho biết trung bình của 'actual time' trong 'flight'
- 11. Caching các dòng dữ liệu duy nhất của df_new. Đếm số dòng. Cho biết thời gian thực hiện các công việc này.
- 12. Đếm lại số dòng. Cho biết thời gian thực hiện các công việc này.
- 13. Kiểm tra xem df new có trong cache hay không? Nếu có thì bỏ df new ra khỏi cache.

```
In [1]: import findspark
    findspark.init()

In [2]: from pyspark import SparkContext
    from pyspark.conf import SparkConf
    from pyspark.sql import SparkSession

In [3]: sc =SparkContext()

In [4]: spark = SparkSession(sc)

In [5]: #1.
    df = spark.read.csv(["AA_data"], header=True, inferSchema=True)
```

```
Ex2 Preprocessing - Jupyter Notebook
In [6]: #2.
        df.count()
Out[6]: 583718
In [7]: df.show(5)
        +-----
        |Date (MM/DD/YYYY)|Flight Number|Destination Airport|Actual elapsed time (Minut
        +-----
              01/01/2014
                                  5|
                                                 HNL |
        519
              01/01/2014
                                 7
                                                 OGG |
        505
              01/01/2014
                                 35|
                                                 SLC|
        174
              01/01/2014
                                 43|
                                                 DTW
        153
              01/01/2014
                                 52
                                                 PIT|
        137
        +-----
        only showing top 5 rows
In [8]: df.printSchema()
        root
         |-- Date (MM/DD/YYYY): string (nullable = true)
         |-- Flight Number: integer (nullable = true)
         |-- Destination Airport: string (nullable = true)
         |-- Actual elapsed time (Minutes): integer (nullable = true)
In [9]: from pyspark.sql.functions import col, udf
        from pyspark.sql.functions import isnan, when, count, col
In [10]: #3. Kiểm tra dữ liệu NaN, null
        df.select([count(when(isnan(c), c)).alias(c) for c in df.columns]).toPandas().T
Out[10]:
                           0
             Date (MM/DD/YYYY) 0
                  Flight Number 0
               Destination Airport 0
        Actual elapsed time (Minutes) 0
In [11]: | # => Không có dữ liệu NaN
```



0

Out[12]:

- Date (MM/DD/YYYY) (
 - Flight Number 0
 - Destination Airport 0
- Actual elapsed time (Minutes) 0

```
In [13]: # Không có dữ Liệu null
```

```
In [14]: #4. Kiểm tra dữ liệu trùng. Xóa dữ liệu trùng.
```

```
In [15]: num_rows = df.count()
```

```
In [18]: dup_rows
```

Out[18]: 0

In [19]: # Không có dữ liệu trùng

Lazy processing operations

```
In [20]: from pyspark.sql.functions import *
```

```
In [21]: #5. Add the airport column using the F.lower() method
df = df.withColumn('airport', lower(df['Destination Airport']))
```

```
In [22]: df = df.drop('Destination Airport')
```

```
Ex2 Preprocessing - Jupyter Notebook
In [23]:
        df.show(5)
           -----
        |Date (MM/DD/YYYY)|Flight Number|Actual elapsed time (Minutes)|airport|
                                  5|
               01/01/2014
                                                          519
                                                                 hn1|
               01/01/2014
                                  7|
                                                          505 l
                                                                 ogg
               01/01/2014
                                 35|
                                                          174
                                                                 slc|
                                 43|
               01/01/2014
                                                          153
                                                                 dtw
                                                          137
               01/01/2014
                                 52
                                                                 pit|
                           -----+---+----
        only showing top 5 rows
        #6. Add column date, using column Date (MM/DD/YYYY), drop Date (MM/DD/YYYY)
In [24]:
In [25]: | df = df.withColumn('date', df['Date (MM/DD/YYYY)'])
        df = df.drop('Date (MM/DD/YYYY)')
In [26]:
In [27]:
        df.show(5)
          -----
        |Flight Number|Actual elapsed time (Minutes)|airport|
          -----+----+-----+
                                           519
                                                  hn1 | 01 / 01 / 2014 |
                   7
                                                  ogg | 01/01/2014 |
                                           505
                  35|
                                                  slc | 01/01/2014 |
                                           174
                  43
                                           153
                                                  dtw|01/01/2014|
                  52
                                           137
                                                  pit | 01/01/2014 |
        only showing top 5 rows
In [28]:
        df = df.withColumnRenamed("Flight Number", "flight_num")
        df = df.withColumnRenamed("Actual elapsed time (Minutes)", "actual time")
In [29]:
        df.show(5)
          -----+
        |flight num|actual time|airport|
                5|
                                hnl | 01/01/2014 |
                         519
                7|
                         505
                                ogg | 01/01/2014 |
                                slc | 01/01/2014 |
               35 l
                         174
```

dtw|01/01/2014|

pit | 01/01/2014 |

Parquet format

43

only showing top 5 rows

153

137

SQL and Parquet

```
In [33]: #10. Register the temp table
    df_new.createOrReplaceTempView('flights')

In [34]: # Run a SQL query of the average Actual elapsed time
    avg_duration = spark.sql('SELECT avg(actual_time) from flights').collect()[0]
    print('The average flight time is: %d' % avg_duration)

The average flight time is: 147
```

Improving Performance

Caching a DataFrame

Caching can improve performance when reusing DataFrames

Counting 583718 rows again took 0.877655 seconds

Removing a DataFrame from cache



```
In [38]: # Determine if df_new is in the cache
    print("Is df_new cached?: %s" % df_new.is_cached)
    print("Removing df_new from cache")

# Remove df_new from the cache
    df_new.unpersist()

# Check the cache status again
    print("Is df_new cached?: %s" % df_new.is_cached)

Is df_new cached?: True
    Removing df new from cache
```

Note: Converting to a larger number of files with approximately equal quantity of rows lets
 Spark decide how best to read the data.

Cluster configurations

Is df_new cached?: False

```
In [39]: # Name of the Spark application instance
    app_name = spark.conf.get('spark.app.name')

# Driver TCP port
    driver_tcp_port = spark.conf.get('spark.driver.port')

# Number of join partitions
    num_partitions = spark.conf.get('spark.sql.shuffle.partitions')

# Show the results
    print("Name: %s" % app_name)
    print("Driver TCP port: %s" % driver_tcp_port)
    print("Number of partitions: %s" % num_partitions)
```

Name: pyspark-shell Driver TCP port: 62414 Number of partitions: 200

```
In [40]: # Store the number of partitions in variable
before = df_new.rdd.getNumPartitions()

# Configure Spark to use 500 partitions
spark.conf.set('spark.sql.shuffle.partitions', 500)

# Recreate the DataFrame using the departures data file
df_new = spark.read.parquet('AA_DFW_ALL.parquet').distinct()

# Print the number of partitions for each instance
print("Partition count before change: %d" % before)
print("Partition count after change: %d" % df_new.rdd.getNumPartitions())
```

Partition count before change: 200 Partition count after change: 500

```
In [41]: ### save data to json file
```

```
In [42]: #df_new.write.json('AA_DFW_ALL.json')
```