

# **Chapter 5: Data Pre-processing**

### Ex1: DallasCouncilVoters

#### Cho dữ liệu DallasCouncilVoters.csv

#### Yêu cầu:

- 1. Đọc dữ liệu => df
- 2. Cho biết dữ liệu có bao nhiêu dòng, in scheme. Hiển thị 5 dòng dữ liệu đầu tiên.
- Kiểm tra dữ liệu NaN, null. Nếu dòng nào 'VOTER\_NAME' có dữ liệu null thì xóa hết các dòng đó.
- 4. Kiểm tra dữ liệu trùng. Xóa dữ liệu trùng.
- 5. Tìm các VOTER NAME duy nhất và hiển thị 10 thông tin đầu tiên.
- 6. Lọc dữ liệu theo điều kiện 'VOTER\_NAME' có chiều dài từ 1-20 ký tự.
- 7. Loại bỏ các dữ liệu mà trong 'VOTER NAME' có chứa dấu ' ' (underscore)
- 8. Tạo cột 'splits' chứa thông tin được cắt theo khoảng trắng từ 'VOTER NAME'
- 9. Tạo cột 'first\_name' lấy dữ liệu từ phần tử đầu tiên trong cột 'splits'
- 10. Tạo cột 'last name' lấy dữ liệu từ phần tử cuối cùng trong cột 'splits'
- 11. Tạo cột 'random\_val' theo điều kiện: nếu cột 'TITLE' có nội dung là 'Councilmember' thì 'random\_val' sẽ có giá trị rand(), nếu có nội dung là 'Mayor' thì 'random\_val' sẽ có giá trị là 2, ngược lại sẽ có giá trị là 0.
- 12. Lọc các dòng dữ liệu có 'random\_val' = 0. Hiển thị.
- 13. Xây dựng function: getFirstAndMiddle(names) trả về kết quả gồm First và Middle (names). Khai báo function vừa viết dưới dạng udf đặt tên là udfFirstAndMiddle.
- 14. Tạo cột first\_and\_middle\_name bằng cách gọi udf trên với tham số truyền vào là cột 'splits'. In kết quả.
- 15. Xóa bỏ các cột 'first name', 'splits'. In kết quả.
- Thêm cột 'ROW\_ID' bằng phương thức: monotonically\_increasing\_id() (trong pyspark.sql.functions).
- 17. Hiển thị 10 dòng đầu của dữ liệu với ROW ID tăng dần.

```
In [1]: import findspark
findspark.init()

In [2]: from pyspark import SparkContext
from pyspark.conf import SparkConf
from pyspark.sql import SparkSession

In [3]: sc =SparkContext()

In [4]: spark = SparkSession(sc)
```

```
In [5]: #1.
         df = spark.read.csv('voters data/DallasCouncilVoters.csv', header=True,
                            inferSchema=True)
 In [6]:
         #2.
         df.count()
 Out[6]: 44625
 In [7]: df.printSchema()
         root
          |-- DATE: string (nullable = true)
          |-- TITLE: string (nullable = true)
          |-- VOTER_NAME: string (nullable = true)
 In [8]: df.show(5)
                                           VOTER NAME
               DATE
                            TITLE
         |02/08/2017|Councilmember| Jennifer S. Gates|
         |02/08/2017|Councilmember| Philip T. Kingston|
         |02/08/2017|
                            Mayor | Michael S. Rawlings |
         |02/08/2017|Councilmember|
                                         Adam Medrano
         |02/08/2017|Councilmember|
                                       Casey Thomas
         +----+
         only showing top 5 rows
 In [9]: from pyspark.sql.functions import col, udf
         from pyspark.sql.functions import isnan, when, count, col
In [10]: #3. Kiểm tra dữ liệu NaN, null
         df.select([count(when(isnan(c), c)).alias(c) for c in df.columns]).toPandas().T
Out[10]:
                      0
                DATE 0
                TITLE 0
         VOTER NAME 0
In [11]: | # => Không có dữ liệu NaN
```

```
In [12]: df.select([count(when(col(c).isNull(), c)).alias(c) for c in
                     df.columns]).toPandas().T
Out[12]:
                        0
                 DATE
                        0
                 TITLE 195
          VOTER NAME 503
In [13]:
         # => Có dữ liệu null. Xóa dữ liệu có VOTER_NAME null
In [14]: | df = df.dropna(subset='VOTER_NAME')
In [15]:
         df.select([count(when(col(c).isNull(), c)).alias(c) for c in
                     df.columns]).toPandas().T
Out[15]:
                       0
                 DATE 0
                 TITLE 0
          VOTER_NAME 0
         # => hết dữ liệu null
In [16]:
In [17]:
         num_rows = df.count()
         num dist rows = df.distinct().count()
         dup_rows = num_rows - num_dist_rows
In [18]: display(num rows, num dist rows, dup rows)
         44122
         1273
```

42849

```
In [19]: # Check duplicate
        df.filter(df['VOTER_NAME'] == 'Philip T. Kingston').show(5)
        +----+
              DATE
                         TITLE
                                    VOTER_NAME
          -----+
        |02/08/2017|Councilmember|Philip T. Kingston|
        |02/08/2017|Councilmember|Philip T. Kingston|
        |01/11/2017|Councilmember|Philip T. Kingston|
        |09/14/2016|Councilmember|Philip T. Kingston|
        |01/04/2017|Councilmember|Philip T. Kingston|
        +----+
        only showing top 5 rows
        df = df.drop duplicates()
In [20]:
In [21]: df.count()
Out[21]: 1273
In [22]:
        #5. Show the distinct VOTER NAME entries
        df.select(df['VOTER_NAME']).distinct().show(10)
         -----+
                 VOTER NAME
          -----+
              Tennell Atkins
          the final
                      20...
               Scott Griggs
               Scott Griggs
               Sandy Greyson
        | Michael S. Rawlings|
         the final 2018 A...
               Kevin Felder
               Adam Medrano
               Casey Thomas
        +----+
        only showing top 10 rows
In [23]: from pyspark.sql.functions import *
In [24]: #6. Filter df where the VOTER NAME is 1-20 characters in length
        df = df.filter('length(VOTER NAME) > 0 and length(VOTER NAME) < 20')</pre>
```

In [25]: df.show(5)



```
In [26]: #7. Filter out df where the VOTER_NAME contains an underscore
    df = df.filter(~ col('VOTER_NAME').contains('_'))
```

```
In [27]: # Show the distinct VOTER_NAME entries again
df.select('VOTER_NAME').distinct().show(10, truncate=False)
```

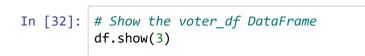
## **Modifying DataFrame**

```
In [28]: #8. Add a new column called splits separated on whitespace
    df = df.withColumn('splits', split(df.VOTER_NAME, '\s+'))

In [29]: #9. Create a new column called first_name based on the first item in splits
    df = df.withColumn('first_name', df.splits.getItem(0))

In [30]: #10. Get the last entry of the splits list and create a column called last_name
    df = df.withColumn('last_name', df.splits.getItem(size('splits') - 1))

In [31]: # Drop the splits column
    # df = df.drop('splits')
```





```
+-----
               TITLE|
                     VOTER NAME
                                   splits|first name
   DATE
|last name|
04/11/2018|Deputy Mayor Pro Tem| Adam Medrano
                              [Adam, Medrano]
                                           Adam
 Medrano
|02/14/2018|
          Councilmember | Lee M. Kleinman | [Lee, M., Kleinman] |
                                           Lee
| Kleinman|
|04/25/2018|
          Councilmember | Tennell Atkins | [Tennell, Atkins] |
                                        Tennell
  Atkins|
+----+
only showing top 3 rows
```

```
In [33]: #11. Add a column to df for any voter with the title 'Councilmember'
df = df.withColumn('random_val', when(df.TITLE == 'Councilmember', rand()))
```

- In [34]: # Show some of the DataFrame rows, noting whether the when clause worked #df.show(5)

```
Ex1 PreProcessing - Jupyter Notebook
In [36]: # Show some of the DataFrame rows
      df.show(5)
      +-----
         +-----
           DATE
                         TITLE
                                   VOTER NAME
                                                    splits|first
      name|last name|
                  random val
      +-----+-----+-----+------
      ----+-----+
      |04/11/2018|Deputy Mayor Pro Tem|
                                Adam Medrano [Adam, Medrano]
      Adam | Medrano |
                            0.0
      |02/14/2018|
                               Lee M. Kleinman | [Lee, M., Kleinman] |
                   Councilmember
      Lee | Kleinman | 0.7266891908590055 |
      |04/25/2018|
                 Councilmember|
                                Tennell Atkins | [Tennell, Atkins]
                                                           Ten
      nell| Atkins|1.716281340619074...|
                                 Kevin Felder| [Kevin, Felder]|
      |08/29/2018| Councilmember
                                                            Κ
      evin
           Felder | 0.047122114981064556 |
      |10/18/2017|
                   Councilmember | Jennifer S. Gates | [Jennifer, S., Ga... | Jenn
      ifer | Gates | 0.47584042942379867 |
      +-----
      ----+
      only showing top 5 rows
In [37]: #12. Use the .filter() clause with random val
      df.filter(df.random val == 0).show(5)
      +-----
      ---+----+
                         TITLE | VOTER NAME |
                                                   splits|first n
          DATE
      ame|last name|random val|
```

```
+-----
---+----+
|04/11/2018|Deputy Mayor Pro Tem| Adam Medrano|
                                      [Adam, Medrano]
                                                      Α
dam| Medrano|
|04/12/2017|
             Mayor Pro Tem | Monica R. Alonzo | [Monica, R., Alonzo] |
                                                    Mon
ica| Alonzo|
           0.0
|06/28/2017|Deputy Mayor Pro Tem| Adam Medrano|
                                      [Adam, Medrano]
dam | Medrano | 0.0 |
|01/03/2018|Deputy Mayor Pro Tem| Adam Medrano| [Adam, Medrano]|
dam | Medrano | 0.0 |
|01/17/2018|
            Mayor Pro Tem|Dwaine R. Caraway|[Dwaine, R., Cara...|
                                                    Dwa
ine| Caraway|
              0.0
+-----
---+----+
only showing top 5 rows
```

#### **UDF**

In [38]: from pyspark.sql.types import \*

```
In [39]: def getFirstAndMiddle(names):
        # Return a space separated string of names
        return ' '.join(names[:-1])
In [40]: #13. Define the method as a UDF
       udfFirstAndMiddle = udf(getFirstAndMiddle, StringType())
In [41]: #14. Create a new column using your UDF
       df = df.withColumn('first_and_middle_name', udfFirstAndMiddle(df.splits))
In [42]: #15. Drop the unnecessary columns then show the DataFrame
       df = df.drop('first_name')
       df = df.drop('splits')
In [43]: df.show(5)
       +-----
           DATE
                           TITLE | VOTER NAME | last name |
       val|first and_middle_name|
       +-----
       ---+----+
       |04/11/2018|Deputy Mayor Pro Tem| Adam Medrano | Medrano |
                       Adam
       |02/14/2018| Councilmember| Lee M. Kleinman| Kleinman| 0.7266891908590
       055
                     Lee M.
       |04/25/2018| Councilmember| Tennell Atkins| Atkins|1.71628134061907
       4...
                    Tennell
       |08/29/2018| Councilmember| Kevin Felder| Felder|0.047122114981064
       556
                      Kevin
       |10/18/2017|
                     Councilmember | Jennifer S. Gates | Gates | 0.47584042942379
                 Jennifer S.
       +-----
       only showing top 5 rows
```

## Adding an ID Field

```
In [44]: # Select all the unique council voters
df = df.select(df["VOTER_NAME"]).distinct()

# Count the rows in voter_df
print("\nThere are %d rows in the df DataFrame.\n" % df.count())
```

There are 27 rows in the df DataFrame.

```
In [45]: #16. Add a ROW_ID

df = df.withColumn('ROW_ID', monotonically_increasing_id())
```

In [46]: #17. Show the rows with 10 highest IDs in the set
df.orderBy(df.ROW\_ID.desc()).show(10)



#### IDs with different partitions

```
In [47]: # Mở rộng
In [48]: # Print the number of partitions in each DataFrame
    print("\nThere are %d partitions in the df DataFrame.\n" % df.rdd.getNumPartition
```

There are 200 partitions in the df DataFrame.

- Make sure to store the result of .rdd.max()[0] in the variable.
- monotonically increasing id() returns an integer. You can modify that value in-line.
- · Make sure to show both Data Frames.

```
In [50]: # Show the ROW_ID from both DataFrames and compare
    df.select('ROW_ID').show(5)
    voter_df_april.select('ROW_ID').show(5)
```



```
ROW_ID
+----+
  8589934592
34359738368
42949672960
51539607552
|103079215104|
+----+
only showing top 5 rows
+----+
      ROW_ID
+----+
|1717986918400|
|1743756722176|
|1752346656768|
|1760936591360|
|1812476198912|
+----+
```

only showing top 5 rows